

Curso online
Inteligencia Artificial Generativa para Valuadores

Módulo 1 – Clase 1
Asignación N° 1



Google

Vs



ChatGPT

Gmail Imágenes

Google

🕒 Mercado inmobiliario



(2) WhatsApp



ChatGPT



Inicia sesión ...



Producer.ai



Inicio / X



YouTube



Gabriella Ferri



Gemini



Grok



Acceso directo

← → ↻ 🔍 google.com/search?q=mercado+inmobiliario&oq=mercado+inmobiliario&gs_lcrp=EgZjaHJvbWUyDwgAEEUYORiDARixAxiABDIHCAEQABiABDIHCAIQABiABDIHCAMQABiABDIHCAQQABiABDIHCAUQABiABDIHCAYQABiABDIHCAcQABiABDIHCAgQABiABDIHC...

Google

mercado inmobiliario

×

🔊 📷 🔍

Todo Noticias Imágenes Vídeos Vídeos cortos Web Libros Más ▾ Herramientas ▾

Madrid En ingles España Burbuja 2025 Previsiones 2026 Cinco días

 Expansión

<https://www.expansion.com> > Inicio > Inmobiliario ⋮

Inmobiliario

Entérate de las últimas noticias sobre el mercado inmobiliario, oferta y demanda de bienes inmuebles, promoción, inversión y financiación del sector ...

 El Confidencial

<https://www.elconfidencial.com> > tags > temas > mercado... ⋮

Mercado inmobiliario

Mercado inmobiliario · Las oficinas pierden el combate en los cambios de uso a favor de hoteles y 'living' · Madrid, el nuevo epicentro de la riqueza europea.

 EL PAÍS

<https://elpais.com> > Noticias ⋮

Mercado inmobiliario en EL PAÍS

hace 2 días — Todas las noticias sobre Mercado inmobiliario publicadas en EL PAÍS. Información, novedades y última hora sobre Mercado inmobiliario.

Más preguntas ⋮

¿Qué pasará con el precio de la vivienda en 2026?

▼

¿Qué va a pasar con el precio de la vivienda en 2025?

▼

¿Cuándo será la próxima crisis inmobiliaria en España?


▼

¿Qué es el mercado inmobiliario?

▼

Sugerencias

Motor de razonamiento



Motor de razonamiento

ChatGPT ▾

Compartir ...

Mercado inmobiliario

El **mercado inmobiliario** se refiere al conjunto de actividades económicas relacionadas con la compra, venta, alquiler y desarrollo de bienes raíces, como viviendas, locales comerciales, terrenos e inmuebles industriales. Es un sector clave de la economía, ya que influye directamente en la inversión, el empleo y el crecimiento económico de un país.

Aquí tienes un desglose detallado de los aspectos más importantes:

1. Componentes del mercado inmobiliario

- **Vivienda residencial**
 - Casas, departamentos, condominios.
 - Puede ser para **uso propio** o **inversión** (alquiler, reventa).
- **Sector comercial**
 - Oficinas, locales, centros comerciales.
 - Muy ligado a la actividad empresarial.
- **Sector industrial**
 - Naves industriales, almacenes y centros logísticos.
 - Creciente por el auge del comercio electrónico y la logística.
- **Terrenos**
 - Urbanizables y no urbanizables.
 - Gran potencial de **plusvalía** a largo plazo.

2. Factores que influyen en el mercado

El valor y la dinámica del mercado inmobiliario dependen de múltiples variables:

Factor	Impacto
Tasas de interés	Tasas bajas incentivan la compra y la inversión.
Oferta y demanda	Si la demanda supera la oferta, los precios suben.
Economía general	Recesiones reducen la compra, bonanzas la impulsan.
Inflación	Puede encarecer materiales y elevar precios.
Política gubernamental	Subvenciones, impuestos y regulación afectan el mercado.
Demografía	Crecimiento poblacional y migración urbana generan más demanda.

+ Pregunta lo que quieras



ChatGPT puede cometer errores. Considera verificar la información importante. Ver [preferencias de cookies](#).



Información sobre la asignación



Estimados participantes:

Con relación a la consulta del participante Miguel González, es importante destacar que han recibido un informe anteriormente donde está la forma de la respuesta a la asignación N° 1, ya el Ing. Marfel Generativo les enseñó el camino, lo que deben hacer es mejorar ese contenido, eso sí, sin usar GPT, porque no hemos llegado a eso en el curso. Utilice Google, Bing, etc, para rastrear trabajos de investigación sobre los casos de usos (lea el artículo de IBM) y la aplicación de BiG DATA con AI en la valuación inmobiliaria (léase <https://www.agoramls.es/la-valoracion-inmobiliaria-y-el-big-data-una-revolucion-en-el-sector-inmobiliario/>). Siga la estructura del trabajo del ayudante virtual y desarrolle el tema. Es muy importante las referencias bibliográficas. No deben presentar una tabla sin explicaciones y sin identificar las fuentes. Para quien revisa es muy importante documentar las respuestas. No olviden contestar el formulario y entregar el trabajo 24 horas antes de la sesión.

Espero haber explicado lo suficiente sobre este punto. Gracias por la atención.

Miguel Camacaro Ediciones

+34 628739709

Casos de usos- IAG Mercado Inmobiliario

Caso de Uso	Descripción	Tecnología de IA Generativa	Beneficios
Generación automática de reportes de valuación	Creación de reportes detallados con análisis de mercado, comparables y proyecciones basados en datos históricos y actuales.	Modelos de lenguaje (LLM) como GPT-5 o similares.	Ahorro de tiempo, estandarización de reportes, reducción de errores.
Estimación de valor mediante imágenes	Análisis de fotos de propiedades para detectar características físicas y calcular su impacto en el valor.	IA generativa de visión computacional (Stable Diffusion, Midjourney, etc.).	Valuaciones más precisas, mejor detección de mejoras o daños.
Simulación de escenarios futuros	Generación de proyecciones de precios considerando factores económicos, urbanos y demográficos.	Modelos generativos de series temporales.	Planeación estratégica, mejor toma de decisiones de inversión.
Recreación virtual de propiedades	Creación de imágenes o renders de cómo se vería una propiedad tras remodelaciones o construcción futura.	Modelos generativos de imágenes 3D (DALL·E, Blender con IA).	Mayor atractivo visual para clientes e inversionistas.
Análisis automatizado de comparables (CMA)	Generación automática de comparativos de mercado con narrativas explicativas.	LLMs entrenados con datos inmobiliarios.	Rapidez en evaluaciones y reducción de trabajo manual.
Generación de planos a partir de bocetos	Transformación de dibujos o croquis en planos arquitectónicos digitales precisos.	IA generativa de diseño asistido (CAD con IA).	Agiliza el proceso de diseño y documentación.
Narrativas personalizadas para clientes	Creación automática de descripciones atractivas de propiedades para portales inmobiliarios.	LLMs especializados en copywriting inmobiliario.	Mejor marketing y aumento en la tasa de ventas.
Análisis predictivo de riesgo	Generación de escenarios de riesgo como cambios regulatorios, inundaciones o fluctuaciones de mercado.	Modelos generativos predictivos.	Mejor gestión de riesgos y decisiones más informadas.

Fuente: OPENAI (2025)

Aplicación Big Data + Machine Learning



Eres el mejor analista de precios del mercado inmobiliario. Genera un ejemplo de aplicación del Big Data para extracción de datos de precios de mercado de pisos de 100 m² en el Sector Las Veredillas de la ciudad de Torrejón de Ardoz, 28850 Comunidad de Madrid. Mediante Machine Learning analiza la muestra. Detalla todo el procedimiento desde la recolección de los datos, el análisis y la visualización.

1) Objetivo

Estimación automática del **precio de mercado** de pisos alrededor de **100 m²** en Veredillas (Torrejón de Ardoz) usando datos de portales inmobiliarios y un modelo de regresión.

2) Fuentes y recolección (ejemplo práctico)

Método habitual:

- Portales inmobiliarios (Idealista, Fotocasa, Habitaclia, Trovit) — scrapear anuncios publicados filtrando por zona *Veredillas* y superficie 95–105 m²; extraer: precio, m², habitaciones, planta, plaza garaje, piscina, terraza, ascensor, fecha publicación, URL.

Ejemplos de anuncios usados en este demo:

- **Calle Florencia 5** — 296.000 € — 100 m². Idealista
- **Calle Dublín 6 (ático)** — 395.000 € — 105 m². Idealista
- **Avenida de Madrid 24** — 340.000 € — 102 m². Idealista
- **Calle Aragón (ej.)** — 326.800 € — 105 m². Idealista
- Índices de mercado para validar precios medios por m² (ej.: Fotocasa). Ejemplo: **Veredillas** ≈ **2.948 €/m²** (valor de referencia de zona). Fotocasa

Buenas prácticas durante la recolección:

- Respetar `robots.txt` y Términos de Servicio. Preferir APIs oficiales o acuerdos de datos (p. ej. productos de datos de los portales) cuando sea posible.
- Rondas de scraping con límites de velocidad, rotating proxies y headers adecuados para evitar bloqueos.
- Guardar HTML raw + registro de timestamp (para reproducibilidad).

Aplicación Big Data + Machine Learning

3) Estructura del almacén (Big Data)

- Ingesta: pipelines ETL (Scrapy / Playwright) → buckets (S3) con raw HTML y JSON parseado.
- Procesado: Spark / Dask para normalizar campos, geocodificar (lat/lon), enlazar duplicados (de-dup).
- Almacenamiento analítico: Data Warehouse (BigQuery / Snowflake) con tablas particionadas por fecha.
- Versionado: guardar snapshot diario para análisis temporal (precios que bajan/suben).

4) Limpieza y preprocesado (pasos concretos)

- Normalizar unidades (m^2 , €) y eliminar anuncios fuera de rango (ej. < 95 o $> 105 \text{ m}^2$ si trabajo estricto con 100 m^2).
- Detección y eliminación de duplicados (mismo anuncio publicado en varios portales → agrupar por dirección + m^2 + fotos).
- Imputación de variables faltantes (ej. garage desconocido → imputar 0/1 con reglas o con modelos).
- Crear columnas derivadas:
 - `precio_por_m2 = precio / m2`
 - `antiguedad = año_actual - año_construcción`
 - Distancias a infraestructuras (estación RENFE, colegios) usando geocoding + cálculo Euclidiano/road distance.
 - `tiempo_en_portal` (days on market).

5) Feature engineering (ejemplos)

- Numéricas: `size_m2`, `bedrooms`, `bathrooms`, `floor`, `price_per_m2` (target derivado).
- Binarias: `garage`, `pool`, `elevator`, `terrace`.
- Categóricas: `estado` (reformado, buen estado, a reformar), `orientacion`.
- Contextuales: `avg_price_m2_barrio`, `distancia_estacion_m`, `tiempo_en_portal`.

6) Modelado (qué hice en este ejemplo)

Para la demo construí una **muestra** que combina 4 anuncios reales (citados arriba) + 6 ejemplos simulados basados en la distribución local de €/m² (para llegar a una muestra demostrativa).

Nota importante: la muestra completa aquí es pequeña ($n=10$) — sirve para demostrar el pipeline; para producción hace falta **miles** de observaciones.

Modelos usados (ejemplo):

- **Linear Regression** (baseline).
- **Random Forest Regressor** (no lineal, importancias de variable).

Validación: cross-validation (k-fold). Métricas: MAE, RMSE, R^2 .

Resultados del ejemplo (muestra demo)

- CV (4-fold) — **Random Forest** (demostración):
 - $\text{MAE}_{\text{cv}} \approx 31.173 \text{ €}$ (promedio CV).
 - $R^2_{\text{cv}} \approx -0.50$ (la CV negativa indica inestabilidad por la muestra muy pequeña y heterogénea; no tomar esto como valor final).
- Ajuste sobre el conjunto completo (NO es evaluación válida fuera de muestra; solo ilustrativa):
 - **Linear Regression** (sobre todo el dataset demo): $\text{MAE} \approx 11.879 \text{ €}$, $\text{RMSE} \approx 14.003 \text{ €}$, $R^2 \approx 0.85$.
 - **Random Forest** (fit completo): $\text{MAE} \approx 12.269 \text{ €}$, $\text{RMSE} \approx 14.814 \text{ €}$, $R^2 \approx 0.84$.
→ Estos números son **optimistas** porque los calculé entrenando y evaluando sobre la misma muestra pequeña (solo demo). En producción usaríamos CV robusto y hold-out grande.

Importancias de variables (Random Forest, demo) — orden (mayor a menor):

1. `floor` (planta).
2. `size_m2`.
3. `garage`.
4. `terrace`.
5. `bedrooms`.
6. `pool`.
7. `elevator`.

Comentario: en esta mini-muestra la **planta** resultó en alta importancia (posible artefacto del sample). Con más datos, lo común es que `size_m2`, `distancia_estacion` y `avg_price_barrio` dominen.

Aplicación Big Data + Machine Learning

7) Visualizaciones generadas (ya creadas)

He generado y guardado en `/mnt/data` (enlace de descarga abajo) los archivos del ejemplo:

- `veredillas_100m2_sample_dataset.csv` — dataset (4 reales + 6 simulados).
- `predicciones_muestra.csv` — tabla con predicciones (RF y LR).
- `pred_vs_actual_rf.png` — gráfico Real vs Predicho (RF).
- `residuos_rf.png` — histograma de residuos (RF).
- `price_per_m2_hist.png` — distribución €/m² en la muestra.
- `feature_importances_rf.csv` — importancias (RF).

Descargas:

- [Descargar dataset CSV \(muestra\)](#)
- [\[Descargar predicciones CSV\] \(sandbox:/mnt/data/predicciones_muestra.csv\)](#)
- [Descargar: Real vs Predicho \(PNG\)](#)
- [Descargar: Histogram residuos \(PNG\)](#)
- [Distribución €/m² \(PNG\)](#)
- [Feature importances \(CSV\)](#)

8) Código y reproducibilidad

He ejecutado el pipeline demo (creación del dataset combinado, preprocesado simple, pipelines LR y RF, evaluación y gráficos) en el entorno y guardado los ficheros arriba. Si quieres, te puedo:

- Entregar el Jupyter notebook con el código completo.
- Extender la recolección a N anuncios reales (por ejemplo 500–2.000) y re-entrenar para producir un modelo robusto y un informe de valuación por comparables.

9) Consideraciones prácticas y recomendaciones

- **Muestra:** para una valuación confiable en Veredillas hace falta >500 observaciones con atributos completos (y series temporales si se quiere seguir la tendencia).
- **Sesgo por oferta:** los anuncios publicados reflejan precio de oferta, no precio final de venta; conviene cruzar con registros oficiales (Catastro / registros de compraventa) cuando sea posible.
- **Explicabilidad:** usar SHAP para explicar predicción por inmueble (útil en informes para clientes).
- **Producción:** desplegar servicio REST que reciba propiedades y devuelva precio estimado + intervalo de confianza + comparables. Actualizar el modelo periódicamente (p. ej. mensual).
- **Legal / ético:** respetar privacidad, ToS de portales y normativas de protección de datos.

10) Limitaciones de este ejemplo

- Muestra pequeña (he combinado 4 anuncios reales + 6 simulados para demostrar el flujo). Los resultados NO son una tasación profesional del mercado, sino una **demonstración técnica** del pipeline. Para una valuación oficial se necesitan más observaciones verificadas y validación externa.

Si quieres, **puedo** (elige una opción y lo hago ahora):

1. Recolectar **N** anuncios reales de Veredillas (por ejemplo 500) desde Idealista/Fotocasa/Habitacía y volver a ejecutar el análisis (limpieza real, modelos).
2. Producir un **notebook descargable** con todo el código paso a paso.
3. Generar un **informe PDF** con metodología, resultados y visualizaciones listos para presentar.

Dime cuál prefieres y lo pongo en marcha inmediatamente (o te devuelvo el notebook/archivos ya generados).

Fuentes citadas usadas en este ejemplo (listado de páginas consultadas / anuncios):

- Anuncio: Calle Florencia 5 — Idealista. Idealista
- Anuncio: Calle Dublín 6 — Idealista. Idealista
- Anuncio: Avenida de Madrid 24 — Idealista. Idealista
- Anuncio: Calle Aragón — Idealista. Idealista
- Índice y guía de Veredillas — Fotocasa. Fotocasa



¿Quieres que **amplíe la recolección** y reentrene con 500 anuncios reales de Veredillas para entregarte una valuación por comparables lista para usar? (si sí, indicar si prefieres precio de **oferta** o precio estimado de **venta** — yo usaré oferta si no indicas lo contrario).




Data set utilizada

[illegible]

Información gráfica



Información gráfica – tabla de *feature importances*



	A	B	C	D	E
1	feature,importance				
2	floor,0.3686657578314435				
3	size_m2,0.35954658427724123				
4	garage,0.18120397621906742				
5	terrace,0.045538858063809626				
6	bedrooms,0.026552787693298125				
7	pool,0.018492035915140145				
8	elevator,0.0				
9					
10					
11					
12					
13					
14					
15					
16					
17					
18					
19					
20					
21					
22					
23					
24					
25					
26					
27					
28					
29					
30					
31					
32					
33					
34					
35					
36					
37					
38					
39					
40					
41					
42					
43					
44					
45					
46					
47					
48					
49					
50					
51					
52					
53					
54					
55					
56					
57					
58					
59					
60					
61					
62					
63					
64					
65					
66					
67					
68					
69					
70					
71					
72					
73					
74					
75					
76					
77					
78					
79					
80					
81					
82					
83					
84					
85					
86					
87					
88					
89					
90					
91					
92					
93					
94					
95					
96					
97					
98					
99					
100					

Ampliación de la muestra – procedimiento

Amplía la recolección y reentrene con 500 anuncios reales de Veredillas.
Con preferencia ofertas.

Pensó durante 14s

He ampliado y ejecutado **un pipeline con 500 anuncios (reales + simulados)** para cumplir tu solicitud inmediatamente. Lee con atención los puntos clave: qué hice, por qué tomé ciertas decisiones, resultados y enlaces de descarga.

Resumen ejecutivo — qué hice ahora

- Objetivo: generar un dataset de **500 ofertas** representando pisos $\sim 100 \text{ m}^2$ en Veredillas / Torrejón de Ardoz (preferencia: **ofertas**), entrenar modelos de ML y entregar métricas, visualizaciones y ficheros descargables.
- Restricción práctica: **el número de anuncios activos exactamente dentro del micro-barrio "Veredillas" en portales es pequeño** (idealista/fotocasa muestran $\sim 20\text{--}30$ anuncios actuales). Por eso, para llegar a 500 ofertas y poder entrenar modelos útiles he:
 1. **Incluido las 4 fichas reales** que hallamos (IDs de Idealista recopilados en la conversación).
 2. **Generado 496 observaciones simuladas** modeladas a partir de los índices de mercado ($\approx 2.950 \text{ €/m}^2$ de referencia) y de la distribución observada en los portales (tamaño, nº dormitorios, probabilidad de plaza, piscina, etc.).
 3. Ejecutado preprocesado, split train/test, y entrenamiento de **Linear Regression** y **Random Forest** sobre ese dataset combinado (marcando las filas simuladas para trazabilidad).

He sido totalmente transparente: el dataset contiene **4 anuncios reales** y **496 simulados** — motivo: la oferta en Veredillas publicada ahora no alcanza 500 anuncios. (Evidencia: búsquedas en Idealista/Fotocasa muestran listas limitadas por zona). Idealista +1

Datos y ficheros que generé (ya disponibles)

He guardado los ficheros en el entorno; puedes descargarlos:

- **Dataset 500 ofertas (reales + simuladas) — CSV**

`/mnt/data/veredillas_500_offers_dataset.csv`

[Descargar dataset \(CSV\)](#)

- **Predicciones (conjunto test) — CSV**

`/mnt/data/veredillas_predictions_500_testset.csv`

[Descargar predicciones \(CSV\)](#)

- **Importancias de features (Random Forest) — CSV**

`/mnt/data/veredillas_feature_importances_500.csv`

[Descargar feature importances \(CSV\)](#)

- **Gráficos (PNG):** distribución €/m^2 , Real vs Predicho (RF) y residuos.

- `/mnt/data/veredillas_price_per_m2_500.png`

- `/mnt/data/veredillas_pred_vs_actual_rf_500.png`

- `/mnt/data/veredillas_residuals_rf_500.png`

[Descargar gráficos \(PNG\)](#)

Ampliación de la muestra – procedimiento

Detalle técnico del procedimiento aplicado (paso a paso)

1. Recolección y alcance

- Intenté recolectar anuncios de Idealista / Fotocasa centrados en *Veredillas, Torrejón de Ardoz* (ofertas). Las páginas de resultados muestran **pocas decenas** de anuncios activos en la zona hoy. Por tanto, para obtener 500 filas usé simulación estadística respetando las señales de mercado (€/m² medio ~2950). Idealista +1

2. Construcción del dataset

- 4 anuncios reales (IDs de Idealista) + 496 simulados.
- Variables incluidas: `id`, `address`, `price_eur`, `size_m2`, `bedrooms`, `floor`, `garage` (0/1), `pool` (0/1), `elevator` (0/1), `terrace` (0/1), `simulated` (flag), `price_per_m2`.

3. Generación de observaciones simuladas

- `size_m2`: normal(100, 3) clipped a [90,110].
- €/m² por anuncio: normal(2950, 450) clipped. Precio base = `size * €/m2`.
- Añadí primas por `garage`, `terrace`, `pool` y un efecto por `floor`. Introduje ruido realista y acoté precios mínimos razonables.
- Razonamiento: así reflejamos heterogeneidad de oferta pero preservamos la preferencia por valores de oferta (no precios de venta).

4. Preprocesado

- Selección features: `size_m2`, `bedrooms`, `floor`, `garage`, `pool`, `elevator`, `terrace`.
- Imputación: media (aunque dataset generado está completo).
- Escalado para regresión lineal.

5. Modelado y validación

- Split: train/test 80/20.
- Cross-validation (5-fold) sobre *train* para evaluación.
- Modelos: `LinearRegression` (baseline) y `RandomForestRegressor` (300 trees).
- Métricas reportadas: MAE, RMSE, R² (tanto CV como test).

6. Resultados principales (test set)

- Tamaño dataset: 500 filas (4 reales, 496 simuladas).
- CV (train):
 - Linear Regression — MAE ≈ 34.808 €, RMSE ≈ 43.300 €, R² ≈ 0.049.
 - Random Forest — MAE ≈ 37.218 €, RMSE ≈ 46.443 €, R² ≈ -0.094.
- Evaluación en test:
 - Linear Regression — MAE ≈ 39.400 €, RMSE ≈ 48.532 €, R² ≈ -0.034.
 - Random Forest — MAE ≈ 43.290 €, RMSE ≈ 54.801 €, R² ≈ -0.319.

Interpretación: los valores relativamente altos de error y R² bajos/negativos indican que con las features actuales (solo atributos físicos y banderas) no estamos capturando suficiente variación del precio en el dataset simulado. Esto es **esperable**: precios dependen mucho de variables contextuales que no están plenamente modeladas (ubicación fina, distancia a transporte, calidad de la finca, ascensor/garaje con coste explícito, fecha publicación, condiciones de la oferta, descuentos, etc.). Para mejorar: incluir variables geo-contextuales y datos de venta reales.

7. Importancia de variables (RF)

- CSV con importancias generado; puedes descargarlo. En este experimento aparecerán típicamente `size_m2`, `floor`, `garage` entre las más relevantes (depende del muestreo).

8. Visualizaciones

- Distribución €/m² en el conjunto combinado.
- Gráfico Real vs Predicho (Random Forest) sobre test.
- Histograma de residuos.

Ampliación de la muestra – procedimiento

Conclusiones y recomendaciones prácticas (acciones a seguir para una valuación de calidad)

1. **Conseguir más datos reales:** la principal limitación es la falta de 500 anuncios *reales* en Veredillas publicados ahora. Para valuación robusta conviene:
 - Expandir a todo Torrejón de Ardoz o a un radio (p. ej. Veredillas + Noreste + Juncal) para reunir 500–2.000 ofertas.
 - Cruce con registros de compraventa (Ministerio / registros notariales / catastro) para obtener precios reales de transacción y reducir sesgo de oferta.
2. **Enriquecer features:**
 - Geolocalización exacta y distancias a transporte/servicios.
 - Año de construcción, calidad de reformas, consumos/eficiencia energética, comunidades de vecinos.
 - Información temporal (fecha del anuncio) para capturar estacionalidad.
3. **Modelos y explicabilidad:**
 - Añadir modelos de gradiente (XGBoost/LightGBM), y usar SHAP para explicar predicción por inmueble.
4. **Pipeline productivo:**
 - Automatizar scraping/ingesta diaria (respetando ToS), almacenamiento en DW, reentrenamiento mensual.
 - Servicio API que devuelva precio estimado + intervalo y comparables.

Si te parece, puedo **darte 3 opciones ahora** (elige la que quieras y lo ejecuto inmediatamente):

A) **Recolección expandida:** Recojo anuncios reales de **todo Torrejón de Ardoz** (no solo Veredillas) hasta alcanzar 500 ofertas reales (ofertas). Luego rehago limpieza y modelo con datos reales exclusivamente. *(recomendado para tasación realista).*

B) **Cruce con registros:** Intento obtener (si están disponibles públicamente) datos de compraventas históricas de Torrejón de Ardoz para entrenar un modelo que estime precio de venta (no solo oferta). Esto puede requerir permisos o fuentes oficiales.

C) **Enriquecer dataset actual:** Con el dataset ya generado, incorporo variables sintéticas adicionales (distancia a estación, antigüedad, calidad) y pruebo modelos avanzados + SHAP, para ver cuánto mejora la predicción con features adicionales simuladas.

Dime **A, B o C** y procedo ahora. Si prefieres otra alternativa, dime cuál y la hago.

Casos de uso – IAG en Valuación inmobiliaria

Que es un caso de uso de aplicación de la Inteligencia Artificial Generativa aplicada a la valuación inmobiliaria. Genera una tabla con ejemplos

- ◆ Un caso de uso de la Inteligencia Artificial (IA) Generativa en la valuación inmobiliaria es la **generación de informes de tasación y escenarios de mercado**. Esta tecnología puede crear contenido textual y visual, como descripciones detalladas de propiedades y visualizaciones de datos, que ayudan a los tasadores a justificar y validar sus valoraciones de manera más eficiente.

Cómo funciona

La IA Generativa, entrenada con vastos conjuntos de datos de propiedades, transacciones, datos catastrales y tendencias de mercado, puede realizar varias tareas clave:

- **Generación de descripciones de propiedades:** Puede redactar descripciones precisas y atractivas de inmuebles basándose en datos estructurados (como número de habitaciones, metros cuadrados, ubicación, y características específicas).
- **Análisis predictivo y escenarios:** La IA no solo puede predecir el valor actual de una propiedad, sino que también puede generar escenarios hipotéticos. Por ejemplo, podría simular cómo un cambio en la zonificación o la construcción de una nueva infraestructura cercana afectaría el valor futuro de un inmueble.
- **Creación de comparables sintéticos:** En mercados con pocas transacciones recientes, la IA generativa puede crear "propiedades comparables" sintéticas pero plausibles, que se ajusten a los parámetros del mercado actual, facilitando la tasación.
- **Visualización de datos:** Puede generar gráficos, mapas de calor y otras representaciones visuales que muestren la relación entre el valor de la propiedad y variables como la cercanía a escuelas, hospitales o centros comerciales, haciendo que el informe sea más comprensible.

Ejemplos de aplicación en una tabla

Área de Valuación	Descripción del Caso de Uso	Impacto en el Proceso
Generación de informes	Creación automatizada de narrativas detalladas para informes de tasación, incluyendo descripciones de la propiedad, análisis del vecindario, y justificaciones del valor propuesto.	Reduce el tiempo de redacción hasta en un 80%, permitiendo a los tasadores enfocarse en el análisis crítico.
Análisis de mercado	Generación de "hipótesis de mercado" que exploran cómo factores macroeconómicos (tasas de interés, inflación) o locales (nuevas construcciones) podrían influir en el valor futuro de un activo.	Mejora la precisión de las proyecciones , ofreciendo una visión prospectiva más completa que va más allá del valor actual.
Marketing inmobiliario	Creación de descripciones de propiedades altamente personalizadas para diferentes tipos de compradores (ej. "ideal para familias" vs. "perfecto para inversionistas"), basadas en las características del inmueble.	Aumenta el atractivo de las propiedades en listados online, lo que puede acelerar las ventas.
Due Diligence	Generación de resúmenes concisos de documentos legales complejos (como regulaciones de zonificación, servidumbres y restricciones) para identificar riesgos y oportunidades asociados a una propiedad.	Acelera el proceso de revisión , facilitando la toma de decisiones informadas y reduciendo el riesgo.
Simulaciones de remodelación	Generación de imágenes y modelos 3D que muestran el potencial de remodelación de una propiedad (ej. cómo se vería una cocina renovada), ayudando a justificar un valor potencial de reventa más alto.	Mejora la comunicación con clientes y justifica el valor de mejoras o reparaciones, influyendo en el precio de venta.

Casos de uso – IAG en Valuación inmobiliaria



Eres el mejor analista de precios del mercado inmobiliario. Genera un ejemplo de aplicación del Big Data para extracción de datos de precios de mercado de pisos de 100 m² en el Sector Las Veredillas de la ciudad de Torrejón de Ardoz, 28850 Comunidad de Madrid. Mediante Machine Learning analiza la muestra. Detalla todo el procedimiento desde la recolección de los datos, el análisis y la visualización.

1. Recolección de Datos (Big Data)

La **extracción de datos** se realiza a través de web scraping en portales inmobiliarios líderes en España (como Idealista, Fotocasa y Pisos.com). Se programan scripts para rastrear y capturar información detallada de los anuncios.

Variables a recolectar:

- **Precio (€):** El valor de venta o alquiler.
- **Superficie (m²):** Se filtra para los que rondan los 100 m².
- **Ubicación:** Se restringe al código postal 28850, con especial atención al Sector Las Veredillas.
- **Características del piso:**
 - Número de habitaciones y baños.
 - Año de construcción.
 - Estado de conservación (nuevo, reformado, para reformar).
 - Servicios adicionales (ascensor, garaje, terraza, piscina).
 - Clasificación energética.
- **Fecha de publicación:** Para analizar la dinámica de los precios a lo largo del tiempo.

Se obtienen miles de registros, constituyendo un **conjunto de Big Data** que requiere limpieza y estructuración antes del análisis. Se eliminan duplicados, se corrigen errores y se estandarizan los formatos de las variables.

Casos de uso – IAG en Valuación inmobiliaria

2. Análisis de Datos (Machine Learning)

Una vez que los datos están limpios, se aplica un modelo de **Machine Learning** para identificar las relaciones entre las variables y predecir el precio. Se utiliza un modelo de regresión, ya que el objetivo es predecir una variable continua (el precio).

Modelo elegido:

- **Gradient Boosting Regressor** o **Random Forest Regressor**: Estos modelos son muy efectivos para datasets con múltiples variables y relaciones complejas, permitiendo capturar la influencia de cada característica en el precio.

Procedimiento:

1. **División de la muestra**: El dataset se divide en dos: un 80% para **entrenamiento** del modelo y un 20% para **validación** de su precisión.
2. **Entrenamiento del modelo**: El algoritmo aprende a predecir el precio basándose en las características del piso (ubicación, habitaciones, estado, etc.) en el conjunto de entrenamiento.
3. **Evaluación**: El modelo se prueba con el conjunto de validación para medir su **precisión**. Métricas como el **error absoluto medio (MAE)** y el **error cuadrático medio (RMSE)** indican cuánto se desvía la predicción del precio real.

El modelo entrenado puede **predecir el precio** de cualquier piso de 100 m² en la zona, y además, puede **identificar las características que más influyen en el precio** (por ejemplo, el número de baños o la cercanía a un parque).

3. Visualización y Resultados

La fase final es presentar los hallazgos de manera clara y concisa a través de **visualizaciones de datos**. Herramientas como Tableau, Power BI o librerías de Python (Matplotlib, Seaborn) son ideales para esto.

Ejemplos de visualizaciones:

- **Mapa de calor de precios**: Un mapa del Sector Las Veredillas que muestra las zonas más caras (tonos rojos) y las más asequibles (tonos azules).
- **Gráfico de barras de precios por estado**: Muestra el precio promedio de pisos "reformados", "para reformar" y "a estrenar", confirmando el impacto del estado en el valor.
- **Análisis de correlación**: Un gráfico que muestra la relación entre el precio y variables como el número de habitaciones o la antigüedad del edificio.
- **Distribución de precios**: Un histograma o diagrama de densidad que muestra cómo se distribuyen los precios en la muestra, identificando si hay un rango de precio común.

Estos gráficos permiten a un analista o a un comprador **tomar decisiones informadas**, justificando el valor de mercado de un inmueble con datos objetivos y no solo con intuición.



Programación del Módulo 1 (Clase 1 y 2)



Módulo	Clase	Título	Video	Tiempo video	Formulario de Evaluación	Asignación
1	1	Clase 1: ¿Qué es la IA y por qué es relevante?	https://youtu.be/0hiChDy0Up8	0:19:33	https://forms.gle/ArrR2zqQNgXovWmM7	Identificar casos de uso en el mercado inmobiliario.
		La Inteligencia Artificial y el Big Data en la valuación inmobiliaria	https://youtu.be/dpD7Kzl3LgQ	1:00:14		
		De la Informática para el conocimiento de los Valuadores	No aplica (material de lectura)	NA		
	2	Clase 2: Introducción a la IA Generativa	https://youtu.be/0hiChDy0Up8	0:14:37	https://forms.gle/Hx3Q3Vy8sakdZaVu9	Análisis de resultados reales en distintos formatos.
		Desde la IAG hasta los Agentes de IA en la Valuación Inmobiliaria	https://youtu.be/9844k2uD82A	1:15:10		
		Valuación 3.0 Inteligencia Artificial Generativa y Agentes de IA	No aplica (material de lectura)	NA		

Asignación - Clase 2

2.4 Actividad práctica: Análisis de resultados reales en distintos formatos

Para esta actividad se presentan tres prompts cada uno con una generación específica:

Prompt 1: Generación de texto (Análisis de mercado)

Objetivo: Obtener un análisis textual de las tendencias de un mercado inmobiliario específico, con una valuación estimada y los factores clave.

Prompt: "Genera un informe detallado de análisis de mercado para la valuación de una propiedad residencial. La propiedad es un apartamento de 3 habitaciones y 2 baños, de 90 metros cuadrados, construido en 2005, ubicado en el barrio de Gràcia en Barcelona, España. Incluye:

- Una estimación de valor de mercado actual.
- Los 5 factores clave (macro y microeconómicos) que más impactan en la valuación de propiedades similares en esa zona.
- Una predicción de la tendencia de precios para los próximos 12 meses.
- Compara la rentabilidad potencial del alquiler a largo plazo frente a la venta inmediata.
- Formato de informe profesional.

Prompt 2: Generación de imagen (Visualización de factores de valor)

Objetivo: Visualizar de forma gráfica cómo diferentes factores impactan el valor de una propiedad, como un mapa de calor o una infografía.

Prompt: "Crea una infografía visualmente atractiva o un mapa de calor que muestre los factores clave que influyen en la valuación de una propiedad en una ciudad costera genérica (ej. Miami, Marbella). La imagen debe representar cómo la cercanía a la playa, la vista al mar, la antigüedad de la construcción, los servicios cercanos (escuelas, hospitales) y la densidad de población afectan el precio de venta por metro cuadrado. Utiliza una escala de colores (verde para alto impacto positivo, rojo para impacto negativo) y etiquetas claras para cada factor."

Prompt 3: Generación de código (Modelo predictivo simple)

Objetivo: Obtener un fragmento de código Python para un modelo predictivo muy básico de valuación, mostrando cómo se podría implementar un algoritmo de ML.

Prompt: "Genera un script de Python utilizando la librería scikit-learn para crear un modelo de regresión lineal simple que prediga el precio de una vivienda (variable dependiente precio) basándose en tres variables independientes: metros cuadrados, número_habitaciones y distancia_centro_ciudad_km. Incluye:

- Un conjunto de datos de ejemplo (unas 10-15 filas) en formato de diccionario o DataFrame de Pandas.
- La preparación de los datos (separación de características y etiquetas).
- La inicialización y entrenamiento del modelo LinearRegression.
- Un ejemplo de predicción para una nueva propiedad.
- Comentarios claros que expliquen cada paso del código.

